

智服通AI客服中台产品需求文档（PRD）

2026年 7月 1日

目录

一、产品定位与目标	3
1.1 产品概述	3
1.2 项目背景与目标	3
1.3 目标用户画像	4
1.4 使用场景与用户旅程	4
二、功能需求说明	5
2.1 核心功能列表	5
2.2 详细功能说明	6
三、非功能与专项需求	9
3.1 性能与兼容性需求	9
3.2 安全性与权限控制	9
3.3 数据管理规范	10
3.4 模型能力专项要求	11

3.5 伦理与合规性考虑	12
四、实施与验证机制	13
4.1 实施计划与里程碑	13
4.2 测试与验证策略	14
4.3 异常兜底与持续优化	15
五、附录与参考资料	16
A. 设计资产与原型资源	16
B. 技术契约与接口定义	16
C. 背景研究与决策依据	17
参考文献	17

一、产品定位与目标

1.1 产品概述

智服通AI客服中台是一款面向企业级客户的智能客户服务解决方案，旨在通过大模型驱动的AI Agent架构，实现多模态输入理解、任务自动拆解与跨系统工具调用，提供零代码配置的自动化客服响应能力。

本产品支持文本、语音、图像等多种用户咨询方式，适用于电商、金融、教育等高频服务场景，核心价值在于降低人工客服负荷30%以上，提升首次响应效率至15秒内，并确保服务一致性与合规性。

1.2 项目背景与目标

需求背景

- 行业趋势：客户服务正从“人工主导”向“AI协同”演进，企业对降本增效的需求日益迫切。
- 用户反馈：现有客服系统难以处理复杂多轮对话，且缺乏上下文记忆与意图连贯性。
- 竞品压力：头部厂商已推出具备长上下文（128K）与MoE稀疏激活技术的AI客服产品，形成性能优势。

业务目标

- 量化指标：在上线6个月内，帮助客户实现工单首次响应时长缩短40%，人工介入率下降至20%以下。
- 功能覆盖：支持至少5类典型服务场景（如订单查询、退换货办理、账户问题处理等）的全自动闭环处理。

用户目标

- 作为终端用户，希望获得即时、准确、无需重复描述问题的服务体验。
- 作为运营人员，期望通过**可视化流程编排界面**快速配置新业务场景，无需依赖开发团队。

1.3 目标用户画像

角色	特征	核心痛点	主要期望
客服运营主管	负责团队绩效与服务质量，关注KPI达成	人力成本高、新人培训周期长、高峰期响应延迟	自动化处理常见问题，释放人力聚焦复杂咨询
IT系统管理员	技术背景强，负责系统集成与安全合规	担忧数据泄露、接口兼容性差、部署复杂	提供标准API、支持私有化部署、满足等保二级要求
终端消费者	年龄跨度大，使用习惯多样	对机器人回复不耐烦、需多次转接人工	快速解决问题，避免重复输入信息

1.4 使用场景与用户旅程

典型使用场景

- 场景1：用户上传一张订单截图，询问发货状态。
- 场景2：用户语音提问“我的上一笔退款怎么还没到账？”
- 场景3：连续追问多个相关问题（如先问配送时间，再问能否修改地址）。

用户旅程图

1. 发起请求：用户通过App、网页或电话提交咨询。

- 2. 多模态解析：系统识别文本/语音/图像内容，提取关键实体（如订单号、商品名称）。
- 3. 意图理解与上下文关联：结合历史对话判断当前诉求是否为延续性话题。
- 4. 任务执行：调用订单系统API获取物流信息，生成自然语言回复。
- 5. 完成响应：返回结构化答案，并提示可继续追问。

用户故事示例： As a customer service manager, I want the AI system to handle routine inquiries automatically, so that our human agents can focus on high-value, emotionally sensitive issues.

二、功能需求说明

2.1 核心功能列表

本产品核心功能围绕多模态理解、智能决策与自动化执行构建，所有功能均需支持在单会话内12轮上下文长度范围内保持语义连贯性。功能优先级依据业务影响度与技术实现成本综合评定。

功能ID	功能名称	功能描述	优先级
F001	多模态输入解析	支持文本、语音、图像三种用户输入方式的自动识别与关键信息提取	P0
F002	上下文关联与记忆	在连续对话中自动识别话题延续性，避免用户重复提供背景信息	P0
F003	意图识别与任务拆解	将复杂用户请求分解为可执行的原子任务序列，并调用相应工具模块	P0

F004	跨系统API调用	集成订单、物流、账户等内部系统接口，实现数据查询与状态更新	P1
F005	自然语言生成与响应	基于结构化结果生成符合人类表达习惯的自然语言回复	P0

验收标准示例（Given-When-Then）： Given 用户已上传一张包含订单号的截图， When 系统完成图像OCR识别并匹配到有效订单， Then 应返回该订单当前物流状态的自然语言摘要，且响应时间 ≤ 1.4 秒。

2.2 详细功能说明

F001：多模态输入解析

- 触发条件：用户通过App或网页提交咨询请求
- 操作流程：
 1. 判断输入类型（文本/语音/图像）
 2. 文本直接进入NLP处理管道
 3. 语音经ASR转写为文本（支持中英双语）
 4. 图像执行OCR识别，提取文字内容及商品图特征
- 规则说明：
 - 语音转写准确率目标 $\geq 95\%$
 - 图像仅支持JPG/PNG格式，分辨率不低于720p
- 异常处理：
 - 无法识别的语音提示“未检测到清晰语音，请重试”
 - OCR失败时启用人工审核队列

F002: 上下文关联与记忆

- 触发条件：用户在同一会话中发起新提问
- 操作流程：
 1. 提取当前问题中的实体与意图
 2. 匹配历史对话中的相关上下文片段
 3. 构建增强型输入提示（Prompt）供模型推理
- 规则说明：
 - 单会话记忆上限为12轮交互
 - 敏感信息（如身份证号）不在记忆范围内
- 异常处理：
 - 上下文冲突时以最新一轮输入为准
 - 记忆超限时提示“您已达到本次对话最大轮数，建议开启新会话”

F003: 意图识别与任务拆解

- 触发条件：接收到用户完整输入后
- 操作流程：
 1. 使用分类模型判断一级意图（如“订单查询”、“退换货”）
 2. 若为复合意图（如“查订单+改地址”），拆解为独立子任务
 3. 触发对应的工作流引擎执行路径
- 规则说明：
 - 一级分类准确率要求 $\geq 92\%$
 - 不支持无依据推断行为（如主观判断“用户情绪急躁”）
- 异常处理：
 - 无法识别意图时引导用户选择预设问题模板

F004: 跨系统API调用

- 触发条件：任务拆解后需获取外部数据
- 操作流程：
 1. 根据任务类型选择目标API（如订单服务、用户中心）
 2. 构造符合Schema定义的请求参数
 3. 执行调用并接收JSON格式响应
- 规则说明：
 - 所有API通信必须通过HTTPS加密传输
 - 超时阈值设定为2秒，超过则触发降级策略
- 异常处理：
 - 接口不可用时切换至缓存数据或规则引擎兜底方案

F005: 自然语言生成与响应

- 触发条件：获得任务执行结果或知识库答案
- 操作流程：
 1. 将结构化数据转换为自然语言模板
 2. 注入个性化变量（如用户名、订单号）
 3. 输出最终响应并记录日志
- 规则说明：
 - 幻觉率控制在 $\leq 0.8\%$ ，即不得编造训练数据未覆盖的事实
 - 输出需符合品牌语调规范（专业但不失亲和）
- 异常处理：
 - 生成失败时返回标准化错误提示“服务暂时不可用，请稍后再试”

三、非功能与专项需求

本章节定义“智服通AI客服中台”在功能性之外的关键系统约束与质量保障要求，涵盖性能、安全、数据治理、模型能力及伦理合规等维度，确保产品具备高可用性、可维护性与社会可信度。

3.1 性能与兼容性需求

系统必须满足企业级服务的响应效率与平台适配能力，具体指标如下：

- 响应时间：
 - P99延迟 $\leq$ 1.4秒（从请求接收到完整响应返回）^[1]
 - 验证标准：在模拟1000并发用户场景下持续压测30分钟，达标率 $\geq$ 99.9%
- 并发处理能力：
 - 支持 $\geq$ 1000个并发会话同时运行
 - 单节点支持每秒处理 $\geq$ 200次API调用请求
- 平台兼容性：
 - 操作系统：iOS 12+、Android 8.0+、Windows 10+、macOS 10.15+
 - 浏览器：Chrome 90+、Safari 14+、Firefox 85+、Edge 90+
 - 移动端SDK需提供React Native与Flutter双版本支持
- 网络适应性：
 - 在4G弱网环境下（RTT $\geq$ 300ms），核心功能仍可降级可用

3.2 安全性与权限控制

为保障企业数据资产安全，系统实施多层次防护机制：

- 数据传输安全：

- 所有客户端与服务器通信必须通过HTTPS加密传输，TLS版本不低于1.2 ^[2]
- 访问控制策略：
 - 基于RBAC（角色访问控制）模型实现权限分级
 - 未登录用户仅可使用基础问答功能，无法访问账户或订单信息
- 敏感信息保护：
 - 用户手机号、身份证号等PII字段在前端展示时自动脱敏（如138****1234）
 - 日志系统禁止记录完整银行卡号、密码等高危字段
- 审计与追溯：
 - 所有API调用、配置变更操作需记录操作人、时间戳与变更内容，保留日志不少于180天

3.3 数据管理规范

数据是AI系统的核心生产资料，其质量与合规性直接影响模型表现与法律风险。

维度	要求说明	引用
数据来源	内部历史对话记录（≥50万条）、第三方公开语料库、客户授权业务数据	^[3]
数据清洗标准	去除重复样本、过滤低质量文本（含乱码、广告）、统一编码格式为UTF-8	^[4]
标注一致性	关键意图分类任务需由≥3名标注员独立标注，Kappa系数≥0.8方可入库	^[5]
隐私合规	遵循GDPR第32条与《个人信息保护法》要求，用户数据不出境，存储于境内云节点	^[1]

3.4 模型能力专项要求

作为AI驱动产品，模型性能与行为边界需明确定义并可量化验证。

模型性能指标

- 准确率：一级意图分类准确率 $\geq 92\%$ [1]
- 召回率：关键业务场景（如退换货）意图识别召回率 $\geq 88\%$
- 幻觉率：输出中出现无依据事实的比例 $\leq 0.8\%$ ，定义为“生成实体不在训练集或知识库覆盖范围内” [6]
- 推理速度：平均单次响应生成速度 ≥ 80 tokens/秒（A100 GPU环境）

输入输出标准

- 输入字段：
 - user_input（字符串，必填）：原始用户输入内容
 - session_id（字符串，可选）：用于上下文关联
 - user_profile（JSON对象，可选）：包含用户等级、历史偏好等辅助信息
- 输出Schema：

```
1 {  
2   "response_text": 自然语言回复",  
3   "intent_code": "INTENT_ORDER_QUERY",  
4   "confidence": 0.95,  
5   "tool_calls": [...],  
6   "requires_human_handoff": false  
7 }
```

模型能力边界

- 支持语言：中文、英文、日文、韩文
- 上下文长度：单会话内支持最多12轮历史记忆（约16K tokens）^[7]
- 禁用行为：不得对用户情绪、紧急程度进行主观判断；不支持医疗诊断、法律建议等高风险领域回答

3.5 伦理与合规性考虑

为构建负责任的人工智能系统，需前置评估潜在社会影响并建立治理机制。

- 公平性保障：
 - 模型在性别、年龄、地域维度上的预测偏差率差异不得超过5个百分点
 - 定期执行偏见检测测试，并生成可解释性报告
- 法规适配：
 - 符合中国《生成式人工智能服务管理暂行办法》第七条关于内容安全的要求
 - 通过国家信息安全等级保护二级测评（等保2.0）^[1]
- 人工兜底机制：
 - 当系统置信度低于阈值（<70%）或用户明确要求时，自动转接至人工坐席
 - 提供“举报错误回答”入口，用户反馈将进入模型再训练闭环
- 算法透明度：
 - 向客户提供XAI（可解释AI）输出样例，说明关键决策路径
 - 在管理后台展示模型调用链路 with 置信度分布热力图

四、实施与验证机制

为确保“智服通AI客服中台”按期高质量交付，并在上线后持续稳定运行，本章节定义完整的实施路径、测试验证策略及长期维护机制。所有流程均围绕功能与非功能需求展开，保障产品从开发到运维的全生命周期可控可测。

4.1 实施计划与里程碑

项目采用敏捷开发模式，划分为五个关键阶段，每个阶段设定明确交付成果与时间节点，确保进度透明、责任清晰。

- 阶段一：需求分析与原型设计（第1-2周）

完成PRD终稿评审，输出高保真Figma原型图，涵盖核心交互流程与管理后台界面^[3]。

- 阶段二：模型训练与微调（第3-6周）

基于清洗后的50万条历史对话数据进行意图识别模型训练，目标一级分类准确率 $\geq 92\%$ ；同步完成OCR与ASR子模型适配。

- 阶段三：系统开发与集成（第7-10周）

实现多模态输入解析管道、上下文记忆模块及API网关对接；完成前后端联调，支持P0级功能闭环。

- 阶段四：用户验收测试（UAT）（第11周）

邀请3家试点客户参与真实场景测试，覆盖订单查询、退换货办理等5类高频场景，收集反馈并优化体验。

- 阶段五：灰度发布与正式上线（第12周起）

按10%→50%→100%流量比例逐步放量，监控关键指标波动，确认无重大缺陷后全面开放服务。

硬性约束：GPU显存使用不得超过16GB，训练数据不得出境，满足境内合规要求^[6]。

4.2 测试与验证策略

建立多层次测试体系，覆盖代码逻辑、系统性能与用户体验，确保各项需求可验证、可追溯。

测试类型与覆盖范围

测试类别	执行方式	覆盖重点	引用
单元测试	自动化脚本	核心算法逻辑、工具调用函数	^[8]
集成测试	接口自动化+人工验证	多模块协同、API通信稳定性	^[9]
压力测试	JMeter模拟并发	P99 延迟 ≤1.4 秒、1000并发支撑能力	^[1]
回归测试	CI/CD流水线触发	新版本对旧功能的影响验证	^[10]

验收标准（Given-When-Then范式）

- Given 用户已连续对话10轮且未中断，

When 提出新的订单查询请求， Then 系统应自动关联历史订单号并返回物流状态，响应时间≤1.4秒^[1]。

- Given 系统检测到API接口超时（>2秒），

When 当前任务依赖该接口返回数据， Then 触发降级策略，使用缓存信息或规则引擎生成响应，避免服务中断^[8]。

4.3 异常兜底与持续优化

为应对不可预见的技术故障与业务变化，建立完善的异常处理机制与模型迭代闭环。

异常处理路径

- 检索为空时：放宽非核心匹配条件重新执行查询，如忽略用户提问中的模糊时间描述。
- 响应超时：切换至轻量级规则引擎提供基础回答，并记录事件用于后续分析。
- 置信度过低时：当模型输出置信度低于70%，自动转接人工坐席并标注需关注问题类型。

模型监控与再训练机制

- 漂移检测：每日比对线上预测分布与训练集差异，若KL散度超过阈值则触发告警。
- 反馈闭环：用户通过“举报错误”入口提交的问题将进入标注队列，每两周更新训练数据集。
- 版本迭代：每月发布一次模型小版本，每季度进行大版本升级，确保能力持续进化。

维护承诺：提供7×24小时技术支持，SLA承诺服务可用性 $\geq 99.95\%$ ，故障响应时间 ≤ 15 分钟。

五、附录与参考资料

为保障“智服通AI客服中台”产品开发的可追溯性与工程落地效率，本附录汇总关键支撑性资料链接与参考依据，供研发、测试及运维团队调用。

A. 设计资产与原型资源

- Figma高保真原型图

包含用户端对话界面、运营后台流程编排面板、管理员监控仪表盘等核心页面，用于前端开发与交互验证^[3]。

链接：<https://figma.com/proto/ai-cs-platform-v1>

- UI组件库与设计规范

提供标准色值（主色#2568C0科技蓝）、字体层级（阿里巴巴普惠体）、图标集及动效参数，确保多端体验一致性^[11]。

B. 技术契约与接口定义

- RESTful API响应示例

定义核心接口的数据结构与字段说明，支持前后端并行开发：

```
1  {
2    "request_id": "req_20260601_xyz",
3    "response_text": "您的订单预计明天上午送达。",
4    "intent_code": "INTENT_LOGISTICS_QUERY",
5    "confidence": 0.93,
6    "tool_calls": [
7      {
8        "name": "query_order_status",
9        "arguments": {"order_id": "ORD20260530"}
```



```
10     }  
11     ],  
12     "requires_human_handoff": false  
13 }
```

字段说明详见《API契约文档v1.0》[\[12\]](#)

- WebSocket长连接协议说明

支持实时语音流传输与增量文本返回，适用于电话客服场景，最大延迟容忍 $\leq 800\text{ms}$ [\[13\]](#)。

C. 背景研究与决策依据

- 竞品分析摘要（Top5厂商）

对比头部AI客服产品在长上下文支持、多模态能力、私有化部署成本等维度的表现，佐证本产品技术路线选择合理性[\[6\]](#)。

- 业务规则附录

列出需硬编码的政策条款编号与处理逻辑，如《电商售后服务规范第3.2条》关于退换货时效的判定条件[\[7\]](#)。

- AI分析过程日志样本

提供模型训练阶段的关键决策记录，包括数据清洗策略变更、标注标准迭代版本，用于审计追溯[\[14\]](#)。

参考文献

[1] AI需求设计文档 - CSDN文库

- [2] AI时代下的PRD撰写：如何利用AI工具轻松生成专业产品需求文档_mob6454cc773039的技术博客_51CTO博客
- [3] 海螺AI怎么做产品需求文档？ -人工智能-PHP中文网
- [4] 确定产品要求和编码准则 - Training \{\}| Microsoft Learn
- [5] Perplexity AI怎么做产品需求分析_Perplexity AI PRD辅助撰写教程【产品】 -人工智能-PHP中文网
- [6] AI智能体流水线搭建：一句话生成标准PRD！阿里云/本地部署OpenClaw+百炼Coding Plan免费接入教程-阿里云开发者社区
- [7] 海螺AI能不能帮我做完整的APP产品需求文档PRD？ 从功能到交互全覆盖-人工智能-PHP中文网
- [8] 我用AI写PRD踩过的所有坑，都帮你总结好了 \{\}| 人人都是产品经理
- [9] 关于AI生成测试用例的实践记录（一） - 第二个卿老师 - 博客园
- [10] 如何利用AI工具高效生成需求文档（PRD） _mob64ca13f4c367的技术博客_51CTO博客
- [11] 人工智能科技领域商业计划书与工作总结PPT模板：简约大气设计，适配产品介绍及汇报场景 - CSDN文库
- [12] 豆包AI怎么写PRD文档_豆包AIPRD方法【教程】 -人工智能-PHP中文网
- [13] Vibe Coding–初识AI编程 - NE_STOP - 博客园
- [14] 大模型 AI 赋能需求设计与分析：从“低效扯皮”到“精准提效”的实战指南-腾讯云开发者社区-腾讯云